

Trop simple OU trop compliqué

Le dilemme biais-variance et l'art de généraliser

Modèle trop simple


Biais élevé

Hypothèse trop simpliste

Underfitting

Trop peu de données
Erreur Train élevée
Erreur Test élevée

Sous-apprentissage



Modèle trop complexe

Variance élevée

Trop sensible aux données de train

Overfitting

Erreur Train proche de 0
précision proche de 0
Erreur Test explose
écart massif

Sur-apprentissage

Régularisation Lasso (L1)

Quand l'utiliser ? Trop de variables créent du bruit et réduisent l'interprétabilité du modèle.

Le Concept : Force mathématiquement les coefficients des variables inutiles à être strictement égaux à 0.

La Formule :

$$RSS + \alpha \sum_{j=1}^p |\beta_j|$$

Pénalité L1 : valeur absolue des coefficients

Sélection automatique Méthode embedded : la sélection de variables est intégrée à l'entraînement. Produit un modèle creux (sparse) et interprétable.

Effet : Élimine le bruit → maximise l'interprétabilité pour le client.

Régularisation Ridge (L2)

Quand l'utiliser ? Colinéarité : variables fortement corrélées → explosion des coefficients et surapprentissage.

Le Concept : Écrase les coefficients vers 0 de façon uniforme : modèle stable, mais aucune variable n'est annulée.

La Formule :

$$RSS + \alpha \sum_{j=1}^p \beta_j^2$$

Pénalité L2 : carré des coefficients

Répartition collective Lissage et minimisation collective du poids des variables. Conserve toutes les variables (0 sélection).

Effet : Maximise la robustesse face à la colinéarité, sans éliminer aucune variable.

Évaluer l'erreur réelle : la K-Fold Cross-Validation

Train


▶ On entraîne le modèle

Validation (folds CV)

▶ On compare les hyperparamètres

Test

▶ Évaluation finale, jamais touché avant



GridSearch

Teste toutes les combinaisons d'hyperparamètres : entraînement → validation croisée → score.
La meilleure combinaison est retenue.

Peut-on encore overfitter avec GridSearch + CV ?

Oui, tester trop de combinaisons revient à optimiser pour les folds eux-mêmes → les hyperparamètres choisis ne généralisent pas sur de vraies données inconnues. C'est l'overfitting des hyperparamètres.

Solution : Réserver un jeu de test final, jamais utilisé pendant le GridSearch.